

# 面向真实搜索的交互式文本-图像行人重识别综述

从噪声对应鲁棒学习到多模态大模型驱动测试时意图对齐

作者姓名

学院/研究机构, 邮箱

2026 年 7 月 18 日

## 摘要

【写作要点】用 250-350 字依次概括研究背景、双重噪声问题、综述分类框架、四类交互机制、对 RDE 的升级设想及主要判断。摘要应突出一个核心观点：真实 TIReID 的主要瓶颈同时来自训练阶段的图文错误对应与测试阶段的不完整查询，多轮交互可被理解为一个面向候选集的主动消歧和动态重排序过程。

**关键词：**文本-图像行人重识别；交互式检索；多模态大语言模型；噪声对应；测试时适应；主动消歧

## 1 引言

### 1.1 研究背景与真实搜索需求

文本-图像行人重识别 (Text-to-Image Person Re-identification, TIReID) 旨在根据自然语言描述, 从大规模图像库中检索与查询人物身份一致的行人图像。相较于依赖目标图像的传统行人重识别, TIReID 允许用户直接描述人物的性别、服饰、随身物品、姿态和局部外观, 因而适用于查询图像不可获得的监控检索、失踪人员搜索和跨摄像头追踪等场景。该任务需要同时克服视觉与语言之间的模态差异, 并从大量外观相近的行人中识别具有区分力的细粒度属性。近年来, 视觉语言预训练模型显著增强了图文表征和跨模态对齐能力, 推动 TIReID 从全局语义匹配逐步发展到局部属性交互和行人领域预训练 [4, 5]。

现有方法取得的进展通常建立在两个理想条件之上。其一, 训练图像与文本能够提供准确、充分且一致的监督。其二, 用户可以在一次查询中完整描述目标人物。真实场景往往难以满足这些条件。监控图像可能受到遮挡、视角、光照和分辨率的影响, 人工描述也可能出现标注错误或与图像弱相关, 从而形成错误的图文对应 [4]。在测试阶段, 用户通常依据短暂观察或模糊记忆组织查询, 输入文本容易过于简短, 并缺失包、鞋、图案和局

部配饰等关键线索。不同用户还可能采用主观、口语化或含混的表达方式，使模型难以从初始查询中恢复真实搜索意图 [3, 5]。因此，TIReID 在真实搜索中的核心困难已经超出静态跨模态匹配，还涉及不完整信息条件下的意图识别与持续校正。

## 1.2 从单轮匹配到测试时闭环对齐

传统 TIReID 主要采用单轮检索范式。模型在训练阶段学习固定的图像编码器、文本编码器和相似度函数，在测试阶段将用户查询视为不可改变的输入，通过一次前向计算得到候选排序。该范式能够高效处理描述充分的查询，却缺少在排序结果存在歧义时继续获取信息的能力。当多名候选人物具有相似的服装颜色和整体外观时，模型只能依赖已有查询和内部参数知识进行判断。即使离线模型已经学习到较为鲁棒的跨模态表示，也无法主动确认用户是否记得目标人物携带背包、衣服是否带有图案，或某一含混词语具体指向何种视觉属性。

大语言模型（Large Language Model, LLM）和多模态大语言模型（Multimodal Large Language Model, MLLM）的发展为测试时交互提供了新的技术条件。ChatIR 较早建立了对话式图像检索协议，由 LLM 根据历史生成后续问题，并将用户回答累积为检索上下文 [2]。PlugIR 进一步表明，直接输入未经处理的多轮对话可能偏离预训练检索器熟悉的文本分布，新增内容甚至会表现为检索噪声。为此，该方法将对话重构为描述性查询，并利用当前候选图像的信息约束问题生成，从而支持对黑盒检索器的即插即用交互 [1]。这些研究说明，多轮交互能否带来稳定收益，不仅取决于获得了多少新文本，还取决于系统是否提出与当前候选差异相关的问题，以及检索器能否正确吸收新增信息。

交互思想随后被引入细粒度人物检索。DIDL 通过协同查询细化、动态上下文重采样和概率上下文匹配，使模型适应逐轮变化的对话式查询 [3]。ICL 则在测试阶段检查高排名候选，围绕人物属性开展视觉问答，将补充信息合并到原始查询，并通过分数融合完成重排序 [5]。由此形成的测试时闭环包含初始检索、歧义判断、问题生成、回答获取、查询更新和候选重排等连续环节。每轮交互都利用当前检索状态决定下一步需要获取的信息，使查询意图与目标图像的对齐过程由一次性映射转变为渐进式推断。

## 1.3 训练噪声与测试噪声的统一视角

真实 TIReID 面临的第一类不确定性来自训练阶段的噪声对应（Noisy Correspondence, NC）。噪声对应指图像与文本在训练数据中被标记为正对，但二者实际存在错误匹配、弱相关或信息冲突。此类错误正对会向对比学习和排序学习提供不可靠监督，并在深度网络的记忆效应下诱导模型逐渐拟合虚假的视觉语义关系。RDE 针对这一问题提出鲁棒双嵌入方法（Robust Dual Embedding, RDE），利用全局与局部嵌入的置信共识筛选可靠图文对，并通过稳定的三元组对齐损失降低噪声监督对优化过程的干扰 [4]。相关跨模态噪声学习方法也主要沿样本筛选、对应校正、概率建模和鲁棒损失等方向提高离线

训练的可靠性。

第二类不确定性出现在测试阶段。初始文本可能遗漏具有判别力的人物属性，也可能包含歧义、错误记忆和与目标无关的信息。当模型输出多个高相似候选时，单轮相似度无法反映用户真正关注的视觉细节。多轮交互可以通过补充属性逐步降低这种不确定性，但交互过程也会引入新的风险。问题可能重复已有内容，LLM 可能询问候选中不存在的属性，用户或 MLLM 代理可能给出错误回答，检索系统还可能围绕一个错误候选持续补充描述。PlugIR 对对话噪声和冗余问题的分析，以及 ICL 对相似度阈值和原始分数融合的使用，均说明测试时新增信息需要受到相关性与可靠度约束 [1, 5]。

本文将上述问题统一理解为跨模态对应关系在不同阶段的置信度不足。训练阶段需要判断某个图文对能否作为可靠监督，测试阶段需要判断当前查询能否充分区分候选身份，交互阶段还需要判断某个问题与回答是否值得写入查询状态。基于这一视角，不确定性可以在四个层面展开。样本层面关注训练图文对的可靠性，属性层面关注文本描述的缺失与冲突，候选层面关注当前排序分布的混淆程度，轮次层面关注新增反馈能否带来稳定的排序增益。离线噪声鲁棒学习为检索器提供可信的表示基础，测试时交互则根据当前搜索状态补充模型尚未获得的信息。二者共同构成面向真实 TIReID 的完整鲁棒性问题。

## 1.4 综述范围、研究问题与主要贡献

现有研究分别从噪声对应学习、通用对话式图像检索和交互式人物检索等角度展开探索，但不同方向使用的问题定义、交互协议与评价指标仍存在明显差异。噪声对应研究主要关注训练数据中的错误监督，通用交互检索强调问题生成与对话编码，TIReID 交互方法则进一步关注人物属性、动态上下文和细粒度重排序。缺少统一分析时，容易将交互收益简单归因于文本长度增加，也难以区分真实用户反馈、目标图像可见的代理回答和候选图像驱动自动交互。为明确这些方法的适用条件与技术联系，本文围绕以下四个问题组织文献与分析。

- 1) 训练对应噪声、测试查询歧义与交互反馈噪声如何在检索闭环中传播并相互影响。
- 2) 多模态大语言模型如何在测试阶段发现查询歧义、补充人物属性并参与候选重排序。
- 3) ChatIR、PlugIR、DIDL 与 ICL 在目标可见性、提问依据、上下文更新和训练需求方面存在哪些差异。
- 4) 如何将 RDE 从离线鲁棒匹配器升级为具备交互触发、主动提问、可靠更新和动态停止能力的检索系统。

本文的主要工作包括四个方面。第一，构建覆盖训练对应噪声、测试查询噪声和交互过程噪声的分析框架，并从样本、属性、候选和轮次四个层面解释不同噪声的传播路径。第二，按照提问依据、目标可见性、上下文处理、检索器适配和重排序方式，对 ChatIR、PlugIR、DIDL 与 ICL 进行机制级比较，重点分析多轮交互如何动态消除语义歧义、细化人物属性并改善候选排序。第三，提出候选集驱动提问、对话历史压缩和原始检索先验保

持等面向真实搜索的机制判断。第四，利用 RDE 的 BGE-TSE 双粒度判断设计单一的双粒度分歧交互模块 DDI：该模块以两路排序差异和 TSE 细粒度文本线索限定交互对象与问题范围，驱动 MLLM 提问与查询细化，随后完全复用 RDE 原生联合推理。相应实验只使用 RSTPReid，重点验证分歧引导相对于通用候选交互的增量作用。

## 2 任务定义与统一问题建模

### 2.1 单轮 TIReID 基本设定

TIReID 的基本目标是利用人物文本描述检索身份一致的行人图像。设测试图像库为  $\mathcal{G} = \{I_i\}_{i=1}^N$ ，其中  $I_i$  表示第  $i$  张行人图像，其身份标签记为  $y_i \in \mathcal{Y}$ 。给定初始文本查询  $q_0$  及其对应的目标身份  $y_q$ ，正样本集合与负样本集合分别定义为

$$\mathcal{P}(q_0) = \{I_i \mid y_i = y_q\}, \quad \mathcal{N}(q_0) = \mathcal{G} \setminus \mathcal{P}(q_0). \quad (1)$$

检索模型使用文本编码器  $f_{\text{txt}}$  与图像编码器  $f_{\text{img}}$  将两种模态映射到共享表示空间，并通过相似度函数  $s(\cdot, \cdot)$  计算查询与图像的匹配得分

$$S_i^{(0)} = s(f_{\text{txt}}(q_0), f_{\text{img}}(I_i)). \quad (2)$$

按照得分从高到低排列全部图像，可得到初始排序列表

$$\pi_0 = \text{argsort}_{I_i \in \mathcal{G}}^\downarrow S_i^{(0)}. \quad (3)$$

理想排序应使任意正样本的得分高于负样本，即  $S_p^{(0)} > S_n^{(0)}$ ，其中  $I_p \in \mathcal{P}(q_0)$  且  $I_n \in \mathcal{N}(q_0)$ 。现有 TIReID 方法通常通过对比学习、匹配分类或三元组排序损失近似优化这一目标。RDE 进一步利用全局与局部双粒度相似度，在存在训练噪声时学习相对稳定的排序函数 [4]。

设  $r_0(q_0)$  为排序列表中首个正样本的位置。Rank- $K$  判断前  $K$  个结果中是否至少包含一个正样本，适合衡量用户能否在有限浏览范围内发现目标。平均精度均值 (mean Average Precision, mAP) 综合考察全部正样本在排序列表中的位置，平均逆负惩罚 (mean Inverse Negative Penalty, mINP) 则更加关注排名最低的困难正样本。三类指标分别反映早期命中、整体排序与困难样本检索质量，但均建立在查询固定且只执行一次检索的设定之上。

### 2.2 多轮交互式检索设定

交互式 TIReID 将固定查询扩展为随反馈逐轮更新的查询状态。系统从  $q_0$  开始执行初始检索，并选取当前排序中的 Top- $M$  图像构成候选集  $\mathcal{C}_0$ 。第  $t$  轮结束后的交互历史记为

$$\mathcal{H}_t = (q_0, Q_1, A_1, \dots, Q_t, A_t), \quad (4)$$



其中  $Q_t$  为系统提出的问题,  $A_t$  为用户或代理提供的回答。当  $t = 0$  时,  $\mathcal{H}_0 = (q_0)$ , 对应传统单轮检索。ChatIR、PlugIR 和 DIDL 将问题与回答显式保存在对话历史中, ICL 则进一步利用候选图像上的人物属性问答生成精炼查询 [1-3, 5]。

为描述当前候选集的混淆程度, 首先将候选相似度归一化为概率分布

$$p_t(I_i | q_t) = \frac{\exp(S_i^{(t)}/\tau)}{\sum_{I_j \in \mathcal{C}_t} \exp(S_j^{(t)}/\tau)}, \quad I_i \in \mathcal{C}_t, \quad (5)$$

其中  $\tau$  为温度系数。候选熵

$$U_t = - \sum_{I_i \in \mathcal{C}_t} p_t(I_i | q_t) \log p_t(I_i | q_t) \quad (6)$$

可以作为检索不确定性的基本度量。较大的  $U_t$  表示相似度集中程度较低, 当前查询难以区分多个候选。实际系统还可联合 Top-1 与 Top-2 得分间隔、全局与局部嵌入分歧以及属性缺失度判断是否需要继续交互。

一个完整的交互式检索器包含问题策略  $\Phi$ 、查询更新器  $\Psi$ 、重排序器  $\mathcal{R}$  与停止策略  $\Omega$ 。其第  $t+1$  轮状态转移可写为

$$Q_{t+1} = \Phi(\mathcal{H}_t, \mathcal{C}_t, U_t), \quad (7)$$

$$q_{t+1} = \Psi(q_t, Q_{t+1}, A_{t+1}, r_{t+1}), \quad (8)$$

$$\pi_{t+1} = \mathcal{R}(q_{t+1}, \mathcal{C}_t, \pi_t), \quad (9)$$

$$z_{t+1} = \Omega(\mathcal{H}_{t+1}, \pi_{t+1}, U_{t+1}, B), \quad (10)$$

其中  $r_{t+1} \in [0, 1]$  表示回答可靠度,  $B$  表示最大交互预算,  $z_{t+1} \in \{0, 1\}$  表示是否停止。问题策略根据历史、候选差异和不确定性选择新的判别属性。查询更新器将回答转换为增量事实、否定事实或不确定事实, 并控制其写入查询状态的权重。重排序器重新计算候选得分, 也可以动态扩展候选池。停止策略在达到轮次预算、排序置信度足够高或预期信息增益不足时终止交互。

回答来源决定了交互设定的现实程度。真实用户通常依赖记忆回答, 回答内容可能简短、含混或不确定。为了开展大规模离线实验, ChatIR 和 DIDL 等工作使用可见目标图像的视觉语言模型或 MLLM 模拟用户 [2, 3]。这种设置便于控制变量, 但代理获得了真实部署中未必存在的视觉信息。另一类设置仅允许 MLLM 观察当前候选或候选摘要, 用于生成问题、规范化回答或执行候选重排 [1, 5]。因此, 评价交互式 TIReID 时应明确区分真实用户、目标可见代理和候选可见代理, 避免将不同信息条件下的结果直接比较。

### 2.3 三类噪声及其传播路径

交互式 TIReID 的误差来源可以划分为训练对应噪声、测试查询噪声与交互过程噪声。三者分别作用于离线表征学习、初始意图表达和在线状态更新, 并可能通过检索闭环相互放大。表1概括了三类噪声的主要来源、作用机制与典型后果。

训练对应噪声描述监督关系与真实语义关系之间的偏差。设  $c_{ij} \in \{0, 1\}$  表示图像  $I_i$  与文本  $T_j$  的真实对应关系,  $\tilde{c}_{ij}$  表示训练数据提供的对应标签。当  $\tilde{c}_{ij} = 1$  而  $c_{ij} = 0$  时, 负样本被错误标记为正样本, 形成错误正对 (False Positive Pair, FPP)。弱相关图文对虽然可能具有相同身份标签, 但文本仅覆盖图像中的少量属性, 也会提供不完整监督。错误对应会直接改变正负样本关系, 使对比学习和三元组学习推动模型靠近语义不匹配的图文表示。RDE 的 CCD 模块通过双粒度损失共识识别高置信干净图文对, TAL 则降低极端困难负样本对梯度的支配, 从样本选择与损失设计两个层面缓解该问题 [4]。

测试查询噪声描述用户文本与潜在真实意图之间的信息差异。设目标人物的完整属性集合为  $\mathcal{A}^*$ , 从初始查询中解析得到的属性集合为  $\mathcal{A}_0$ 。缺失属性与错误属性分别表示为

$$\mathcal{A}_{\text{miss}} = \mathcal{A}^* \setminus \mathcal{A}_0, \quad \mathcal{A}_{\text{err}} = \mathcal{A}_0 \setminus \mathcal{A}^*. \quad (11)$$

属性缺失会使多个外观相近身份获得相似得分, 歧义表达会造成文本特征偏移, 错误记忆则可能使真正目标在初始排序中被压低。由于  $\mathcal{A}^*$  在真实测试中不可直接观察, 系统通常依据候选熵、排名间隔、属性覆盖率和多粒度排序分歧估计查询噪声。多轮交互的直接目标是选择能够减少  $\mathcal{A}_{\text{miss}}$  或澄清含混属性的问题, 使候选分布随有效反馈逐步集中。

交互过程噪声描述新增问题与回答对查询状态造成的错误更新。设第  $t$  轮关于问题  $Q_t$  的理想回答为  $A_t^*$ , 实际回答为  $A_t$ , 则反馈误差可记为  $e_t = \mathbb{I}(A_t \neq A_t^*)$ 。实际系统无法直接计算  $e_t$ , 因而使用可靠度  $r_t$  估计回答的可信程度。重复问题不会增加判别信息, 询问不存在的属性可能诱发无效回答, 错误锚点上的视觉问答还会将查询逐步拉向错误候选。PlugIR 通过候选感知与冗余过滤约束问题生成, ICL 则保留原始查询得分并设置相似度阈值, 以降低新增信息导致排序漂移的风险 [1, 5]。

表 1: 交互式 TIReID 中的噪声类型与影响。

| 噪声类型   | 主要来源                 | 作用机制                | 典型后果                  |
|--------|----------------------|---------------------|-----------------------|
| 训练对应噪声 | 错误标注、遮挡、低画质、描述与图像弱相关 | 错误正对推动模型学习虚假的视觉语义关系 | 记忆噪声、表示偏移、排序性能下降      |
| 测试查询噪声 | 描述过短、关键属性缺失、歧义词、记忆偏差 | 查询无法区分外观相近的候选身份     | 候选集熵高、Top-1 间隔小、细粒度混淆 |
| 交互过程噪声 | 重复提问、幻觉属性、错误回答、错误锚点  | 新信息在多轮更新中被持续放大      | 查询漂移、确认偏差、重排序不可逆恶化    |

三类噪声在闭环中具有明确的传播顺序。训练对应噪声首先影响图文表示与相似度函数, 偏置的相似度会改变初始候选集。测试查询噪声进一步增大候选混淆, 使系统基于不完整证据选择问题。若问题或回答缺乏可靠性, 交互过程噪声会污染更新查询, 并在后

续轮次中继续影响问题生成与重排序。该过程可以概括为

$$\text{错误监督} \rightarrow \text{表示偏移} \rightarrow \text{候选偏差} \rightarrow \text{错误交互} \rightarrow \text{查询漂移}. \quad (12)$$

因此，完整的交互式 TIReID 系统需要同时控制训练样本置信度、初始查询不确定性与逐轮反馈可靠度。只处理其中一个环节，仍可能在其他阶段产生新的误差累积。

## 2.4 评价交互系统的五个维度

交互式检索的评价对象是一条随轮次变化的排序轨迹，单独报告最后一轮 Rank-1 难以反映系统的全部行为。设  $r_t(q)$  为查询  $q$  在第  $t$  轮的首个正样本排名， $T$  为最大交互轮数。本文从最终检索质量、交互效率、逐轮有效性、用户与计算成本、噪声反馈稳健性五个维度组织评价指标。

**最终检索质量。** 最终轮 Rank- $K$ 、mAP 和 mINP 衡量系统使用完整交互预算后的排序质量。DIDL 进一步区分初始单轮性能、最后一轮性能和多轮平均性能，使交互增益能够与基础检索能力分开观察 [3]。在报告最终结果时，还应同时给出无交互的第 0 轮性能，避免将更强的离线编码器带来的优势归入交互模块。

**交互效率。** 交互系统需要关注目标在预算内何时首次进入可浏览范围。定义截至第  $t$  轮的最佳排名为

$$b_t(q) = \min_{0 \leq j \leq t} r_j(q). \quad (13)$$

Hits@ $K$  判断目标是否曾在任意一轮进入前  $K$  名，适合模拟用户看到目标后立即结束搜索的行为 [2]。PlugIR 提出的最佳对数排名积分 (Best log Rank Integral, BRI) 进一步联合考虑目标排名、达到较好排名所需轮数和高排名区间的改进难度 [1]:

$$\text{BRI} = \frac{1}{|Q|} \sum_{q \in Q} \left[ \frac{\log b_0(q) + \log b_T(q)}{2T} + \frac{1}{T} \sum_{t=1}^{T-1} \log b_t(q) \right]. \quad (14)$$

BRI 越低，表示系统越早将目标提升到更靠前的位置。

**逐轮有效性。** 有效交互应在多数轮次中稳定改善排序。第  $t$  轮的对数排名增益可定义为

$$g_t(q) = \log r_{t-1}(q) - \log r_t(q). \quad (15)$$

当  $g_t(q) > 0$  时，该轮使目标排名上升；当  $g_t(q) < 0$  时，新增反馈引起了性能回退。除平均轮次增益外，还应报告正增益轮次比例、性能回退率和候选熵下降幅度。此类指标能够区分持续有效的消歧过程与依赖个别偶然成功轮次的系统。

**用户负担与计算成本。** 相同检索精度可能对应截然不同的部署成本。用户侧成本包括问题数量、问题长度、回答难度与完成时间，系统侧成本包括 MLLM 调用次数、输入输出词元数、图像处理规模、平均响应时延与显存占用。可以使用单位问题带来的平均排名增益或单位时间带来的 mAP 增益衡量成本效益。对于按需交互方法，还应报告触发交互的查询比例，以判断额外开销是否集中在真正困难的查询上。

**噪声反馈下的稳健性。** 真实用户可能回答错误或选择“不确定”，MLLM 代理也可能产生幻觉。稳健性评测应在不同回答错误率、问题冗余率和错误锚点比例下绘制性能曲线，并报告错误反馈后的恢复率。除此之外，真实用户、目标可见代理与候选可见代理应分别统计结果，因为三种协议提供的视觉信息不同。只有同时报告标准准确性、交互轨迹、成本和噪声压力测试，才能较为完整地判断一个交互式 TIReID 系统是否适合真实搜索场景。

### 3 MLLM 驱动的交互式图像检索前沿

现有 MLLM 交互式图像检索研究主要沿两条路线发展。第一条路线以通用图像检索为对象，重点回答如何建立对话式检索协议、如何生成有价值的问题，以及如何使已有视觉语言检索器利用多轮上下文。ChatIR 与 PlugIR 是其中具有代表性的工作。第二条路线面向 TIReID，将通用对话检索进一步约束到人物属性空间，并处理行人图像中的细粒度差异、动态文本上下文与大规模候选重排序。DIDL 与 ICL 分别代表训练适配和测试时增强两种思路 [1-3, 5]。这四项工作并非处于完全相同的任务设定，而是依次展示了交互式检索的四种关键能力：建立多轮协议、利用候选反馈、学习动态上下文，以及用 MLLM 对既有检索器进行测试时校正。

从系统机制看，交互式检索需要同时解决信息获取、上下文表示和排序更新三个问题。信息获取决定系统下一轮应询问何种属性以及回答者能够观察哪些信息；上下文表示决定新增问答以原始对话、压缩描述或结构化属性的形式进入检索器；排序更新则决定系统执行全库重检索、候选池重排还是原始分数与精炼查询分数的融合。除此之外，还必须区分主检索器是否针对对话数据重新训练，以及回答代理是否能够直接观察目标图像。前者决定方法能否即插即用，后者决定离线评测是否使用了真实部署中不可获得的额外信息。下文因此不以结果数值简单排序四项工作，而是比较它们在交互闭环中解决了什么问题、依赖什么信息，以及留下了何种风险。

#### 3.1 ChatIR 的对话式检索协议

ChatIR 首先将主动对话引入文本到图像检索，建立了由对话构建（Dialog Building, DB）和图像搜索（Image Search, IS）组成的闭环协议 [2]。设第  $t$  轮对话为  $D_t =$



$(C, Q_1, A_1, \dots, Q_t, A_t)$ ，其中  $C$  为用户提供的初始描述。问题生成器  $G$  根据完整历史产生下一问题  $Q_{t+1}$ ，回答者根据其心中的目标图像提供  $A_{t+1}$ 。图像检索器  $F$  将不同长度的对话  $D_t$  投影到视觉嵌入空间，并通过余弦相似度对图像库进行排序。系统在每轮问答后重新检索，因此第 0 轮对应传统单轮文本检索，后续轮次反映新增信息对目标排名的影响。

ChatIR 的核心贡献在于将问题生成器和对话检索器作为两个可独立分析的组件。问题生成器可以采用少样本提示的 LLM，也可以使用强化学习问答代理等既有方案。检索器以 BLIP 为基础，在 VisDial 图像对话数据上使用对比学习进行微调，并将描述、问题和回答通过特殊分隔符拼接为统一序列。作者发现，训练阶段随机遮蔽初始描述有助于模型充分利用问答内容，说明检索器需要学习在不同上下文长度和信息来源之间分配注意力。该设计使交互收益同时取决于问题是否提供新信息以及检索器能否编码对话，两部分中任一环节失效都会限制整体性能。

大规模评测需要回答者持续观察目标图像并回复问题，直接依赖真人会产生较高成本。ChatIR 因此使用 BLIP2 作为视觉对话模型模拟用户，并在较小规模实验中收集真实用户回答以检验代理评测的有效性。论文报告，在包含五万张图像的检索库中，系统经过五轮问答后的 Hits@10 达到 78.3%，而仅使用初始描述时为 64%；真实用户参与的实验也呈现相同的逐轮改善趋势 [2]。这些结果为主动提问能够改善图像检索提供了早期证据，但 Hits@10 属于“截至当前轮是否曾经命中”的累计指标，不能单独证明每一轮的即时排序都在改善。

ChatIR 的限制主要来自问题生成与候选空间之间缺少直接联系。LLM 只观察初始描述和历史问答，并不知道当前高排名候选在哪些视觉属性上存在差异。由此生成的问题可能语义合理，却无法有效划分候选集，也可能重复询问已经明确的信息。另一方面，ChatIR 需要使用视觉对话数据微调检索器，难以直接接入参数不可访问的黑盒系统。完整对话不断增长还会受到文本编码器最大长度限制。对于 TIReID，此类问题更加突出，因为大量候选人物可能共享相同的服装颜色，系统需要围绕包、鞋、图案和局部配饰等细粒度差异主动提问。

### 3.2 PlugIR 的即插即用候选感知交互

PlugIR 针对 ChatIR 的两项部署障碍提出即插即用改造，即对话文本与预训练检索器之间的格式失配，以及问题生成器无法观察当前候选 [1]。作者首先比较 CLIP、BLIP、BLIP2 和黑盒多模态检索模型在逐轮拼接问答时的表现。虽然 Hits@10 可能随轮次增加，但单轮 Recall@10 并未同步提升，部分模型的结果反而下降。这一现象说明累积命中指标可能掩盖单轮查询质量的恶化。未经处理的对话序列偏离了检索器训练时常见的描述体文本分布，新增问答因而可能表现为输入噪声。

为缓解格式失配，PlugIR 使用 LLM 执行上下文重构 (Context Reformulation)，将初始描述与多轮问答压缩为流畅、无重复且接近图像描述的数据形式。检索器每轮只接收

重构后的文本，不需要针对对话数据重新训练。这一策略将适配责任从检索模型转移到查询侧，使白盒模型、黑盒服务和已经微调的检索器均可复用同一交互模块。其价值在于将“获得了新信息”和“检索器能够理解新信息”区分开来。对话内容具有判别力仍不足以保证性能提升，查询形式还需要与下游编码器的输入分布相容。

PlugIR 进一步提出候选感知对话生成 (Context-aware Dialogue Generation)。系统先根据当前查询检索一组高相似图像，对候选嵌入执行聚类，并从各簇中选择相似度分布熵较低的代表图像。代表图像经图像描述模型转换为文字摘要，再与对话历史共同输入 LLM 问题生成器。候选摘要使问题能够围绕当前搜索空间中真实存在的属性展开，降低询问无关对象的概率。该过程仍可能产生重复或无效问题，因此系统先保留无法从现有历史直接回答的问题，再比较加入候选问题前后的相似度分布，并选择 Kullback-Leibler 散度最小的问题。这里的筛选不是直接最大化候选区分度，而是抑制尚未获得答案时便引发过大分布扰动的异常问题，从而降低无关问题造成排序突变的风险。

在评价方面，PlugIR 指出  $\text{Recall}@K$  只反映当前轮次， $\text{Hits}@K$  只关心是否曾经成功，两者均难以同时衡量用户满意度、交互效率和高排名区间的提升。为此，论文提出最佳对数排名积分 BRI，以目标图像截至每轮的最佳排名轨迹为基础计算对数面积。较低的 BRI 表示系统使用更少轮次将目标提升到更靠前位置。该指标使问题生成质量能够通过整个排序过程评价，而不局限于某个固定的  $K$ 。

PlugIR 的候选感知设计为 TIReID 提供了直接启发。有效问题应优先区分当前候选人物，避免按照固定属性清单机械展开。不过，该方法依赖候选图像描述的准确性。图像描述模型若遗漏局部配饰或误判颜色，问题生成器仍会受到错误上下文影响。候选集本身也由当前查询产生，当真实目标未进入候选范围时，围绕错误候选进行精细提问可能进一步收缩搜索空间。因此，候选感知需要与候选多样性维护、全库探索和错误恢复共同设计。

### 3.3 DIDL 的动态上下文学习

DIDL 将交互式检索从通用图像场景推进到 TIReID，并将研究重点由外部查询重写扩展到动态上下文的专门训练 [3]。其整体框架包含协同查询细化 (Collaborative Query Refinement, CQR)、动态上下文重采样 (Dynamic Context Resampling, DCR) 和跨模态概率上下文匹配 (Probabilistic Context Matching Modeling, ProCMM)。CQR 负责产生多轮人物属性问答，DCR 负责构造多样化的对话上下文，ProCMM 则学习静态视觉特征与不断变化的文本语义之间的对应关系。

CQR 由 LLM 提问者和回答者组成。提问者根据初始描述与历史问答生成下一问题，并通过人物属性探索指令优先询问尚未出现的细节，同时限制问题长度和单轮问题数量。真实部署中，用户根据记忆承担回答者角色。为了在公开数据集上进行大规模实验，DIDL 使用能够观察目标图像的 MLLM 模拟回答者，并要求其给出简洁且基于图像内容的回答。经过  $N$  轮交互后，系统得到包含初始描述和全部问答的精炼查询。该过程符合从整体服

饰到局部配饰的粗到细搜索逻辑，但实验中的代理回答者直接获得目标图像，其信息条件明显强于真实用户的模糊记忆。

多轮问答会产生与标准图像描述不同的文本结构。DCR 通过三种操作增强模型对这种动态输入的适应能力。随机顺序操作在保留初始描述位置的同时打乱问答片段，使模型减少对固定轮次顺序的依赖。自适应上下文裁剪根据回答是否包含明确主语决定是否删除对应问题。例如，当回答已经写明“他携带一个白色背包”时，原问题可以移除；当回答只有“白色”时，问题仍需保留以维持语义完整。双粒度掩码分别在句子级和词元级扰动新增对话内容，使模型既能利用丰富上下文，也能在附加信息缺失时依靠初始描述完成匹配。

ProCMM 进一步从全局与局部两个尺度建模动态上下文。全局分支将图像全局表示与不同重采样文本产生的概率分布对齐，使同一图像能够容纳多种上下文表达。局部分支使用跨模态编码器融合文本词元和图像局部块，并通过困难负样本构造学习细粒度人物差异。与只对固定描述进行匹配模型相比，ProCMM 将同一查询在不同轮次和不同重采样条件下视为一组动态语义状态，从训练阶段提高检索器对对话变化的容忍度。

推理时，DIDL 首先使用初始描述从全库选取  $\text{Top-}K_{\text{init}}$  候选作为优选池，后续精炼查询主要在该候选池中重新计算相似度。该策略显著降低了多轮检索的计算量，也使系统集中处理初始查询下的困难候选。其局限在于候选池较早固定，当真实目标未进入初始  $\text{Top-}K_{\text{init}}$  时，后续问答难以实现恢复。另一方面，DIDL 的性能建立在对话数据生成、动态上下文训练和目标可见回答代理之上，训练成本及评测协议均与即插即用方法存在差异。其结果更适合说明动态上下文学习的潜力，尚不能直接等同于真实用户条件下的部署收益。

### 3.4 ICL 的测试时人物属性问答与重排序

ICL 关注现有离线 TIReID 模型在测试阶段缺乏外部校正能力的问题，并提出由测试时人本交互 (Test-time Human-centered Interaction, THI) 与重组数据增强 (Reorganization Data Augmentation, RDA) 组成的交互式跨模态学习框架 [5]。RDA 在训练阶段利用 MLLM 丰富、分解、改写并重组人物描述，以提高文本信息量和表达多样性。THI 与离线模型的训练过程相互独立，负责在测试阶段定位潜在目标候选、补充人物属性并执行重排序。

THI 的第一步是候选锚点定位。给定原始查询，离线检索器产生完整排序，MLLM 随后依次检查高排名候选，并回答“该文本能否准确描述这张图像”。由于通用 MLLM 对行人领域中的细粒度差异判断不够稳定，ICL 使用由正图文对和困难负图文对构成的数据，通过低秩适配 (Low-Rank Adaptation, LoRA) 进行监督微调。当某一候选被判断为“是”时，系统将其视为潜在锚点；若当前候选被判断为“否”，则继续检查下一候选。该机制使用 MLLM 充当离线相似度之外的第二判断器，希望发现模型内部知识难以区分的



困难样本。

锚点确定后，THI 围绕性别、发型、上衣、下装、鞋、随身物品和场景等人物特征执行视觉问答。MLLM 直接观察锚点图像并逐项生成属性答案，再将答案与原始查询合并为流畅、简洁的精炼描述。查询压缩具有两方面作用。其一，避免大量问答超出 CLIP 等文本编码器的长度限制。其二，将零散属性转换为与离线检索器训练分布更接近的描述体文本。该设计与 PlugIR 的上下文重构具有相似动机。ICL 的新增信息来自候选锚点上的自动视觉问答，真实用户没有直接参与测试阶段的问答过程。

在重排序阶段，ICL 将原始查询分数与精炼查询分数进行加权融合，并对锚点候选给予特殊处理。为控制计算成本，系统根据原始 Top-1 相似度阈值和此前候选判断结果选择需要继续交互的查询，减少对明显简单样本的 MLLM 调用。论文还报告，THI 可以接入 CLIP、IRRA 和 RDE 等已有模型，在三个粗粒度数据集上的平均提升分别约为 2.57、1.86 和 1.41 个百分点。轮次分析表明，主要收益集中在前两轮，后续交互的边际增益逐渐减小 [5]。这些结果支持按需触发与早期停止，也说明测试时外部知识可以作为离线检索器的补充。

ICL 的即插即用特性使其与 RDE 的交互式升级最为接近，但其锚点机制存在确认偏差风险。若 MLLM 将错误候选判断为“是”，后续属性问答会围绕该图像补充大量细节，精炼查询将进一步靠近错误候选。固定属性列表也未必针对当前候选之间最有区分力的差异，背景和姿态等属性还容易受到摄像头视角影响。此外，LoRA 领域适配和逐候选视觉问答仍会产生额外成本。因而，更稳健的测试时交互需要保留多个候选假设，以候选分布的信息增益选择问题，并根据回答可靠度自适应控制分数融合权重。

### 3.5 代表性方法的机制比较

表2从信息来源、候选感知、上下文处理、排序更新、检索器适配和主要风险六个维度比较四类代表性方法。这里的“回答来源”尤其需要谨慎解释。ChatIR 和 PlugIR 的设计目标均是由真实用户回答，规模化实验可以使用视觉语言代理。DIDL 在实验中让 MLLM 直接观察目标图像，构成目标可见代理。ICL 则由 MLLM 检查当前候选并自动提取候选属性，更接近测试时模型协作。三种设置获取的视觉信息不同，不能仅依据最终 Rank- $K$  判断交互策略优劣。

四类方法呈现出清晰的技术演进。ChatIR 证明对话能够逐步补足初始描述，并建立了问题生成器与对话检索器协同优化的基本协议。PlugIR 将候选集引入问题生成，同时用查询重构解决原始对话与零样本检索器之间的格式差异。DIDL 进一步把动态上下文视为需要专门学习的数据分布，通过重采样和概率匹配增强模型对多轮语义变化的适应性。ICL 则将外部 MLLM 作为测试时校正器，使已有 TIReID 模型无需重新训练即可获得候选属性补充与后验重排能力。

这些工作也暴露出交互式检索的共同矛盾。候选感知能够提高问题的针对性，但当前



表 2: 代表性交互式图像检索方法的机制差异。

| 方法     | 回答来源与目标可见性            | 候选感知    | 上下文处理        | 排序更新      | 与检索器关系        | 主要风险              |
|--------|-----------------------|---------|--------------|-----------|---------------|-------------------|
| ChatIR | 真实用户或目标可见 VLM 代理      | 无       | 直接编码完整对话     | 每轮全库重检    | 需要对话数据微调      | 问题缺少候选区分力, 长上下文受限 |
| PlugIR | 真实用户或目标可见代理           | 多候选文字摘要 | LLM 重构为描述体   | 每轮调用原检索器  | 支持黑盒即插即用      | 候选描述错误与初始候选偏差     |
| DIDL   | 真实用户设想, 实验使用目标可见 MLLM | 无       | 重采样、剪枝与双粒度掩码 | 固定初始优选池重排 | 训练动态上下文匹配器    | 评测信息较强, 池外目标难以恢复  |
| ICL    | MLLM 直接观察排名候选         | 单候选锚点   | 属性问答后合并为精炼查询 | 原始与精炼分数融合 | 可接入 RDE 等离线模型 | 错误锚点导致确认偏差与查询漂移   |

候选由可能含噪的查询和不完美的检索器产生, 过度围绕单一候选交互会放大早期错误。目标可见的代理回答能够稳定生成完整属性, 却高估了真实用户根据记忆回答时的信息质量。直接拼接全部对话可以保留原始证据, 却容易造成冗余、截断和输入分布偏移。将历史压缩为描述体文本更适合现有检索器, 但压缩过程可能删除否定信息、置信度和属性来源。由此可见, 交互系统需要同时维护原始查询、候选假设和反馈可靠度, 才能在获取新信息的同时抑制查询漂移。

综合四篇工作, 面向真实 TIReID 的测试时交互至少应包含五个环节。首先, 依据候选熵、排名间隔和多粒度分歧判断查询是否需要交互。其次, 从多个高概率候选的差异中选择预期信息增益较高的问题。随后, 将用户回答或 MLLM 反馈写入可追踪、可撤销的查询状态。再次, 在保留原始检索分数的基础上进行可靠度加权重排, 并允许候选池适度扩展。最后, 根据排序置信度、边际增益和用户预算执行停止或回退。ChatIR、PlugIR、DIDL 和 ICL 分别覆盖了其中部分环节, 但尚未在同一框架中同时处理交互触发、多候选问题选择、反馈可靠性和错误恢复。这一缺口也构成后文分析多轮消歧机制并对 RDE 进行交互式升级的直接动机。

## 4 多轮交互的消歧机制与共性局限

上一节以论文为单位介绍代表性方法, 本节将分析单位转换为交互闭环中的关键机制。多轮检索可以被理解为一个受控的信念更新过程。初始文本在图像库中形成候选分布, 系统根据当前不确定性获取新信息, 再通过查询状态更新和候选重排序改变该分布。有效交互应使概率质量逐步集中到身份一致的候选, 同时控制错误问题、错误回答和错误锚点造成的查询漂移。ChatIR、PlugIR、DIDL 与 ICL 分别实现了这一闭环的不同部分, 也共同揭示了交互触发、问题选择、上下文管理、重排序和错误恢复之间的依赖关系[1-3, 5]。

#### 4.1 候选不确定性与交互触发

交互触发首先需要回答当前查询是否存在可通过补充信息缓解的歧义。根据式(5)，初始文本会在高排名候选上形成归一化概率分布。当多个候选得分接近时，候选熵较高，Top-1 与 Top-2 的间隔较小，说明现有描述缺少足以区分这些身份的属性。此时继续依赖同一查询重复检索难以改变排序，引入交互具有较高潜在价值。相反，当一个候选明显占优且全局与局部匹配结果一致时，额外问答带来的边际收益可能低于用户与模型成本。

现有方法对交互触发的处理仍较粗略。ChatIR 通常按照预设轮数持续提问，并在离线评测中将目标进入 Top- $K$  视为成功，但真实系统无法直接观察目标排名 [2]。DIDL 同样设置固定的最大对话轮数，并主要研究模型对不同轮次上下文的适应能力 [3]。PlugIR 根据当前候选构造问题，却没有独立判断某个查询是否值得继续交互 [1]。ICL 向前迈进一步，利用原始 Top-1 相似度阈值和候选判断结果筛选需要交互的查询，减少对简单样本的 MLLM 调用 [5]。其轮次分析还显示，多数增益集中在前两轮，说明统一采用较长对话会产生明显的冗余成本。

仅使用候选熵仍可能混淆两种不同情况。第一种情况是候选中包含真实目标，但候选之间外观相似，新增属性有望改善排序。第二种情况是离线检索器已经将真实目标排除在候选范围之外，此时围绕当前候选提问会在错误搜索区域内继续收缩。高置信错误也可能表现为低熵和较大的排名间隔。因此，交互触发需要同时估计歧义程度和可恢复性。候选熵、排名间隔可以衡量候选内部的混淆，全局与局部嵌入分歧、候选多样性和查询属性覆盖率则有助于发现模型置信度与语义证据之间的不一致。

从决策角度看，系统应比较下一轮的预期排序收益与交互成本。设  $\hat{g}_{t+1}$  表示根据当前历史预测的排名增益， $c_{\text{user}}$  与  $c_{\text{model}}$  分别表示用户负担和模型调用成本，则继续交互的条件可以概括为

$$\mathbb{E}[\hat{g}_{t+1} \mid \mathcal{H}_t, \mathcal{C}_t] > \lambda_u c_{\text{user}} + \lambda_m c_{\text{model}}. \quad (16)$$

这一表述将“是否交互”转化为成本感知的价值预测问题。对于 RDE，基础全局嵌入与词元选择嵌入的排序分歧可以提供额外触发信号，因为两种粒度意见不一致往往意味着整体外观与局部属性尚未形成稳定判断。

#### 4.2 候选驱动的人物属性探索

问题质量决定每轮交互能够减少多少候选不确定性。一个有效问题需要同时满足区分性、可回答性和稳定性。区分性表示不同候选对该问题应产生不同答案，可回答性表示用户能够依据记忆或可见证据作答，稳定性表示该属性在不同摄像头、视角和裁剪条件下保持相对一致。缺少区分性的问题只会延长文本，难以改变排序；缺少可回答性的问题会诱导猜测或“不确定”回答；稳定性较差的属性还可能将同一身份在不同图像中的外观变化误认为身份差异。

四篇工作的问题策略体现了从通用提问到候选约束的演进。ChatIR 的 LLM 只观察初始描述和对话历史，能够发现尚未询问的语义主题，但无法知道哪些属性真正区分当前候选 [2]。PlugIR 将候选图像摘要输入问题生成器，并过滤能够从现有历史直接回答的重复问题，使提问更接近候选划分 [1]。DIDL 通过人物属性探索指令要求问题简短并关注未出现细节，适合逐步丰富查询，但提问者仍主要依赖对话历史，候选差异没有被直接建模 [3]。ICL 在接受候选锚点后按照预设人物属性执行视觉问答，能够稳定补全描述，却可能询问当前候选之间共同具备的属性，产生有限的排序增益 [5]。

TIReID 中的人物属性可以按照搜索阶段分层使用。性别、服饰类别、上衣和下装主色通常具有较高可见性，适合在候选范围较大时进行粗粒度划分。图案、包、帽、鞋、腰带、手持物品和局部配饰具有更强的身份区分能力，适合在高相似候选之间进行细分。姿态、动作、遮挡和背景受到摄像头与拍摄时刻影响，作为身份证据时需要较低权重。属性顺序不应固定不变。例如，当当前候选的上衣颜色已经高度一致时，继续询问颜色几乎没有信息增益，系统应转向包的类型、鞋的颜色或衣服图案等能够产生候选分裂的属性。

回答空间也会改变问题的价值。肯定回答补充新的正属性，否定回答能够排除具备该属性的候选，“不确定”回答则提示系统降低该属性权重并避免继续追问。开放式自然语言回答可以提供丰富细节，但需要 MLLM 将其规范化为可匹配属性。是非问题更容易回答和解析，却可能需要更多轮次才能定位细节。较合理的策略是先使用低负担问题确认属性是否存在，再在必要时追问颜色、类型或位置，并允许用户明确表达无法判断。

综合这些观察，问题选择应以多个高概率候选的差异为基础，同时考虑属性可见性、历史冗余和回答成本。系统可以对 Top- $M$  候选建立结构化属性矩阵，估计每个问题对候选分布的预期划分程度，并选择预期熵下降较大的属性。该设计吸收 PlugIR 的候选感知优势，也避免 ICL 围绕单一锚点持续补充属性所产生的确认偏差。

### 4.3 对话历史的压缩、去冗余与冲突管理

多轮交互获得的信息需要转换为检索器可以稳定使用的查询表示。现有方法主要采用直接拼接、描述体重写、动态上下文训练和属性问答合并四种方案。ChatIR 直接编码初始描述与全部问答，最大程度保留交互证据 [2]。PlugIR 使用 LLM 将历史重构为单段图像描述，以适配零样本检索器的输入分布 [1]。DIDL 通过随机顺序、上下文裁剪和双粒度掩码训练检索器适应对话结构 [3]。ICL 将候选视觉问答压缩为精炼查询，再与原始分数共同用于重排序 [5]。

直接拼接能够保留问题、回答和语义来源，适合具备长上下文能力且经过对话训练的编码器。然而，问题中的大量功能词和重复属性会稀释人物实体信息，文本长度还可能超过 CLIP 等编码器的输入上限。更重要的是，通用视觉语言检索器通常在描述体文本上训练，问答形式与训练分布不一致。PlugIR 的实验显示，随着未经处理的对话变长，部分零样本检索器的单轮 Recall@10 下降，说明新增文本可能同时携带有效属性和格式噪声 [1]。

描述体重写能够删除重复问题并压缩上下文，但生成式摘要也可能损失关键信息。否定回答容易在重写中被弱化，例如“没有背包”若被遗漏，带背包候选将重新获得较高得分。前后冲突也可能被 LLM 强行合并为单一事实。用户先回答“可能是黑色”，随后修正为“深蓝色”，系统需要保留修正过程和置信度，而不能将两个颜色无差别写入同一句描述。属性来源同样重要。用户记忆、候选图像 VQA 和 LLM 推断具有不同可靠性，应在状态中分别记录。

因此，较稳健的交互系统需要同时维护结构化状态和检索文本。结构化状态用于保存原始查询、已确认属性、否定属性、不确定属性、冲突候选、来源轮次和回答可靠度。检索文本则由 MLLM 根据高置信状态生成简洁描述，用于兼容现有文本编码器。结构化状态承担证据记忆与错误恢复，描述体文本承担跨模态编码，两种表示相互配合可以兼顾可追踪性和检索效率。

冲突管理应遵循增量更新原则。新回答先与已有属性进行一致性检查，再根据用户确定性、视觉可见性、历史一致性和代理模型自一致性计算可靠度。高置信修正可以降低旧属性权重，低置信冲突则保留为并行假设。原始查询应作为不可修改的初始证据长期保留，使系统能够在后续反馈导致排序恶化时恢复。MLLM 在这一过程中主要承担信息抽取、同义归一和描述生成，其输出需要受到结构化状态约束。

#### 4.4 查询细化与检索重排序

查询细化和检索重排序是两个相关但不同的过程。查询细化决定当前搜索意图如何表达，重排序决定新意图如何改变候选顺序。相同的精炼查询可以用于全库重新检索、固定候选池重排或动态候选池更新，这三种方案在准确性、计算成本和错误恢复能力上存在不同权衡。

ChatIR 在每轮问答后将完整对话重新映射到共享嵌入空间，并面向整个图像库执行检索，具有较强的全局恢复能力，但计算成本随交互次数增加 [2]。PlugIR 将重构查询输入任意黑盒检索器，通常同样可以重新搜索全库 [1]。DIDL 使用初始查询确定  $\text{Top-}K_{\text{init}}$  优选池，后续仅在池内计算动态上下文相似度，显著降低了计算量，但真实目标若未进入初始候选便难以恢复 [3]。ICL 使用精炼查询对图像重新打分，并将其与原始分数融合，同时对候选锚点进行特殊处理 [5]。这种后验重排适合接入已有模型，但错误锚点可能获得过强的先验优势。

新增反馈改变排序主要通过三种路径。第一，正属性提高语义一致候选的文本图像相似度。第二，否定属性和排除性反馈降低不符合条件候选的得分。第三，原始查询分数作为先验约束更新幅度，防止单轮反馈完全覆盖已有证据。现有描述体检索器更擅长处理正属性，否定信息在自然语言编码中未必形成稳定的排除效果。因此，结构化属性一致性得分可以作为跨模态相似度的补充，显式处理“无背包”“没有帽子”等否定条件。

候选池需要在利用和探索之间保持平衡。固定候选池可以集中处理困难样本并降低



MLLM 视觉输入规模，却依赖初始检索的召回率。每轮执行完整全库搜索具有较强恢复能力，但会增加延迟和计算成本。动态候选池可以保留上一轮高概率候选，同时从全库补充少量与新查询相关的探索图像。当反馈与当前候选普遍冲突时，系统应扩大搜索范围，避免继续在错误局部区域内优化。

分数融合权重应由反馈可靠度自适应决定。用户回答清晰、问题具有高区分力且属性在候选图像中可见时，精炼查询和属性一致性可以获得更高权重。回答含混、前后冲突或来源于低置信 MLLM 判断时，系统应更依赖原始检索分数。对于 RDE，基础全局嵌入适合保持整体人物语义，词元选择嵌入适合评估新增局部属性，两种相似度可以分别参与交互重排，并通过粒度分歧检测异常更新。

#### 4.5 停止策略、确认偏差与错误恢复

交互停止需要在检索置信度、边际收益和用户成本之间取得平衡。固定轮数便于离线实验，却可能让简单查询承担无效交互，也可能在困难查询尚未澄清时过早结束。目标进入 Top- $K$  是 ChatIR 和 PlugIR 等工作常用的评测成功条件，但真实部署中系统不知道目标身份，因而无法直接使用该条件。实际停止策略只能依赖排名间隔、候选熵、属性覆盖率、连续轮次变化和用户主动确认等可观测信号。

现有工作已经提供若干经验依据。ChatIR 显示多轮问答能够持续提升累计命中率，但轮次越多，新增问题越容易出现重复 [2]。PlugIR 的 BRI 指标通过惩罚较晚发生的排名改善强调早期成功，却主要承担评价作用 [1]。DIDL 默认使用固定的最大轮次学习动态上下文，没有针对每个查询自适应分配预算 [3]。ICL 根据相似度阈值筛选交互对象，并观察到主要性能增益集中在前两轮，为按需触发和早期停止提供了直接支持 [5]。

系统可以根据下一轮预期信息增益实施停止。当候选分布已经高度集中、剩余候选在可询问属性上差异很小，或连续两轮未获得正排名增益时，继续交互的价值较低。用户回答“不确定”也可能意味着可用记忆已经耗尽。此时系统应结束问答并展示当前高置信候选，避免强迫用户猜测。对于计算成本较高的 MLLM 视觉问答，停止阈值还应考虑剩余候选数量和每轮需要处理的图像规模。

确认偏差是多轮交互中最危险的错误传播形式。PlugIR 的问题建立在当前候选摘要上，当初始候选偏离真实目标时，后续问题可能持续围绕错误属性展开。DIDL 在实验中由目标可见 MLLM 回答，能够避免多数记忆错误，但真实用户回答可能引入冲突。ICL 的风险更加集中。错误候选一旦被接受为锚点，系统会从该图像提取大量属性，随后精炼查询与错误候选的相似度会进一步上升。单轮错误因而可能通过问题生成、查询更新和重排序形成自增强回路。

错误恢复需要可撤销状态、多候选假设和动态候选扩展共同支持。系统应保存每轮查询状态与排序快照。当新一轮导致候选熵异常上升、全局与局部排序分歧显著扩大、多个已确认属性发生冲突或预测排名增益为负时，可以降低该轮回答权重并恢复上一状态。对

于无法确定唯一锚点的查询，系统应保留若干候选分支，优先提出能够区分这些分支的问题。若当前候选与新反馈普遍不一致，则扩大候选池或恢复全库检索。该过程使系统具备从早期误判中返回的路径。

## 4.6 核心 insight 与设计原则

跨方法分析表明，多轮交互的价值来自受约束的信息增益。查询长度增加仅是表面变化，真正决定检索收益的是新增信息能否划分当前候选、是否能够被用户可靠回答，以及检索器能否以合适形式利用这些信息。基于四篇工作的共同证据与局限，本文形成以下设计原则。

- 1) **以预期收益触发交互。**候选熵、排名间隔和跨粒度分歧用于识别歧义，候选召回与多样性用于判断可恢复性。系统只为具有正预期收益的查询调用用户和 MLLM。
- 2) **以候选差异选择问题。**问题应最大化高概率候选的预期分裂，同时考虑属性稳定性、可见性、回答难度和历史冗余。固定属性清单适合作为问题空间，具体顺序应由当前候选决定。
- 3) **采用双层查询状态。**结构化状态保存正属性、否定属性、冲突、来源和可靠度，描述体文本负责兼容现有检索器。任何新增反馈都通过增量校验写入，原始查询始终保留。
- 4) **维护多候选假设。**单锚点策略具有较高效率，也会放大早期误判。多候选记忆与候选分裂问题能够降低确认偏差，并在真实目标未进入局部候选时保留恢复空间。
- 5) **执行先验保持的可靠重排。**原始检索分数提供稳定先验，精炼查询和属性一致性提供增量证据，融合权重由回答可靠度控制。负反馈需要显式排除机制，避免在描述体编码中被弱化。
- 6) **支持早停与回退。**交互收益通常集中在早期轮次。系统应根据边际增益和成本尽早停止，并在检测到查询漂移时恢复状态、降低反馈权重或扩展候选池。
- 7) **区分交互协议进行评价。**真实用户、目标可见代理和候选可见代理拥有不同信息条件。最终准确率需要与 BRI、交互轮数、模型调用成本、性能回退率和错误恢复率共同报告。

上述原则将四篇工作的局部机制组织为完整的测试时交互链。对于 RDE，最有辨识度的升级方向不是外挂一套通用交互流程，而是利用其 BGE 与 TSE 已经形成的整体-局部双判断。后文据此只设计一个分歧交互模块：将两路排序不一致及 TSE 关注词元转化为 MLLM 的提问依据，并把精炼文本重新送回原始 RDE。

## 5 RDE 的交互式升级方案

### 5.1 从双嵌入互补到双嵌入分歧

对 RDE 的交互式升级不应另行堆叠一套与原模型无关的对话、状态和重排序组件,而应从 RDE 已有的内部判断机制出发。RDE 使用基础全局嵌入 (Basic Global Embedding, BGE) 计算图像 [CLS] token 与文本 [EOS] token 的全局相似度,用于表征人物整体语义;同时使用词元选择嵌入 (Token Selection Embedding, TSE),依据最后一层 Transformer 自注意力权重选择信息性图像 patch 和文本 token,经嵌入变换与最大池化获得细粒度相似度 [4]。原论文的消融实验表明, BGE 与 TSE 在联合推理时具有互补作用。

这种双粒度结构也为测试时交互提供了一个自然入口。当 BGE 与 TSE 给出相近排序时,人物整体外观与局部属性形成一致证据;当两者的高排名候选明显不同时,则说明当前文本可能只支持整体语义,却缺少能够确认局部细节的信息,或者某个局部词元对排序产生了过强影响。换言之, BGE-TSE 分歧可以被解释为 RDE 内部暴露出的“需要补充什么信息”的信号。

基于这一观察,本文只在冻结 RDE 中插入一个双粒度分歧交互模块 (Dual-grained Disagreement Interaction, DDI)。DDI 接收 BGE、TSE 的候选排序及 TSE 选中的文本 token,调用 MLLM 生成一个针对分歧的属性问题,并将回答改写为精炼查询;随后仍由原始 RDE 使用 BGE 与 TSE 联合推理完成检索。整个流程为

RDE 双嵌入推理  $\rightarrow$  BGE-TSE 分歧候选  $\rightarrow$  DDI 交互模块  $\rightarrow$  精炼查询  $\rightarrow$  RDE 原生联合推理。

CCD 与 TAL 均保持为 RDE 的离线训练机制,不在测试阶段重新运行。新增部分只有 DDI,查询更新之后的编码、相似度计算和最终排序均复用 RDE 原实现。

### 5.2 双粒度分歧交互模块

给定第  $t$  轮查询  $q_t$ , RDE 分别得到 BGE 相似度  $S_i^b(q_t)$  与 TSE 相似度  $S_i^e(q_t)$ ,并形成两个 Top- $K$  排序  $\pi_t^b$  和  $\pi_t^e$ 。对于出现在二者候选并集中的图像  $I_i$ ,定义归一化排名分歧

$$d_t(I_i) = \frac{|r_t^b(I_i) - r_t^e(I_i)|}{K}, \quad I_i \in \pi_t^b \cup \pi_t^e, \quad (17)$$

其中  $r_t^b$  和  $r_t^e$  分别表示候选在 BGE 与 TSE 排序中的位置;若候选未进入某一 Top- $K$ ,其位置记为  $K+1$ 。仅按照绝对分歧取 Top- $M$  可能使候选集中在同一排序方向,因此 DDI

分别保留 BGE 偏好与 TSE 偏好的候选：

$$\begin{aligned} \mathcal{C}_t^{b \succ e} &= \text{Top}_{M/2}(r_t^e - r_t^b), \\ \mathcal{C}_t^{e \succ b} &= \text{Top}_{M/2}(r_t^b - r_t^e), \\ \mathcal{C}_t^\Delta &= \mathcal{C}_t^{b \succ e} \cup \mathcal{C}_t^{e \succ b}. \end{aligned} \quad (18)$$

其中  $\mathcal{C}_t^{b \succ e}$  表示 BGE 排名更高的整体语义候选， $\mathcal{C}_t^{e \succ b}$  表示 TSE 排名更高的细粒度候选；若某一方向候选不足，则按式(17)从另一方向补齐。双向选择使 MLLM 能够同时比较两组候选假设，而不会把交互建立在单一分支的偏好上。

除分歧候选外，DDI 还读取 TSE 根据文本自注意力选中的 token，并将其整理为可读的细粒度文本线索  $\mathcal{W}_t$ 。这些线索反映 TSE 分支当前关注的文本内容，但不构成对某一候选排序原因的严格归因。MLLM 的输入由当前查询  $q_t$ 、双向分歧候选  $\mathcal{C}_t^\Delta$ 、候选的 BGE/TSE 排名以及  $\mathcal{W}_t$  组成。模型据此选择一个尚未被当前文本明确确认、且能够区分两组候选的可见人物属性，并生成简短问题。问题只涉及服装颜色与类型、鞋、包、帽、图案、手持物品和局部配饰，不询问身份、背景、摄像头或瞬时姿态。

因此，MLLM 在 DDI 中承担的是分歧条件下的问题生成，而不是对 RDE 内部决策进行因果解释。BGE 与 TSE 分别提供整体和细粒度排序视角，TSE attention-selected token cues 则提供辅助文本线索；三者共同限定交互对象与问题范围。

### 5.3 模块内回答与查询更新

离线实验使用目标配对图像可见的 MLLM 作为用户代理。DDI 的第一次调用依据双粒度分歧生成问题；第二次调用只能观察该文本查询对应的源图像和当前问题，并只回答被询问的属性，不能自由补充完整人物描述，也不能读取身份标签、目标排名、其他候选图像或同身份的其他图像。真实应用中，该回答由用户提供。

设从回答中得到的单条属性事实为  $F_{t+1} = \text{Fact}(Q_{t+1}, A_{t+1})$ ，查询更新写为

$$q_{t+1} = \begin{cases} \text{Update}(q_t, F_{t+1}), & F_{t+1} \text{ 可确认,} \\ q_t, & A_{t+1} \text{ 为“不确定”或属性不可见.} \end{cases} \quad (19)$$

更新过程只加入当前问题对应的事实，不允许代理依据目标图像生成未被询问的信息，并保持与 RDE 原有文本格式及输入长度约束一致。DDI 输出的唯一结果仍是精炼查询  $q_{t+1}$ ，不额外输出属性分数、融合权重或候选约束。

得到  $q_{t+1}$  后，系统直接回到 RDE 原生推理。对任意候选图像  $I_i$ ，最终相似度仍使用 RDE 的双嵌入平均：

$$S_{\text{RDE}}(I_i, q_{t+1}) = \frac{1}{2} (S_i^b(q_{t+1}) + S_i^e(q_{t+1})). \quad (20)$$

因此，交互前后的唯一变化是文本查询，RDE 的图像编码器、文本编码器、TSE token 选择方式和联合推理公式均保持不变。若执行多轮交互，每轮重新计算 BGE/TSE 排序和



TSE 选中词元，DDI 随新的分歧生成下一问题。多轮过程由同一个模块循环调用完成，而不是串联多个在线模块。

## 5.4 实现流程

完整实现只需要在 RDE 推理脚本中增加一个 DDI 调用接口：

- 步骤 1, 使用冻结 RDE 分别保存查询的 BGE、TSE 相似度与排序，同时读取 TSE 选中的文本 token。
- 步骤 2, 按式(18)选出双向平衡的双粒度分歧候选。
- 步骤 3, 调用 MLLM，根据查询、分歧候选、双排序位置和 TSE 细粒度文本线索生成一个判别问题。
- 步骤 4, 使用目标配对图像代理回答当前属性问题，并将该单条事实写入查询。
- 步骤 5, 将精炼查询重新送入 RDE，按式(20)执行原生联合推理；需要下一轮时重复步骤 1-4。

这一方案没有修改 RDE 的训练目标，也没有增加新的打分器，新增内容始终保持为一个边界清晰的交互模块。

# 6 实验设计与验证框架

实验只验证一个核心命题：利用 BGE-TSE 分歧指导交互，是否比不交互的 RDE 以及不区分双嵌入来源的通用候选交互更有效。数据集只使用 RSTPReid，现有方法仅引用论文公开结果，不复现 ChatIR、PlugIR、DIDL、ICL 或 THI。表格中的“-”为待实验填写项。

## 6.1 数据集与实现设置

RSTPReid 包含 4,101 个身份的 20,505 张行人图像，每个身份有 5 张图像，每张图像配有 2 条文本描述。官方划分使用 3,701 个身份训练、200 个身份验证和 200 个身份测试 [4]。RDE 使用其公开训练配置获得，并在交互实验中完全冻结。

快速实验从 200 个测试身份中各固定抽取 1 条文本及其配对源图像，共形成 200 条查询，图像库使用完整测试库。该结果标注为“200-query subset”，不与完整测试查询上的论文公开结果直接等价比较。默认设置  $K = 5$ 、 $M = 4$ 、最多 3 轮，每轮提出 1 个问题。提示词、MLLM 配置与交互超参数仅在验证集查询上确定，并在测试前全部固定。

每轮 DDI 使用一次问题生成和一次目标图像代理回答。所有方法使用相同的冻结 RDE、交互轮数与回答代理，以保证比较只反映候选选择策略的差异。

## 6.2 评价指标

检索性能报告 Rank-1、Rank-5、Rank-10 和 mAP。为验证 DDI 是否确实缩小双粒度判断差异，额外报告 BGE 与 TSE 的候选重合率

$$\text{Overlap}@K_t = \frac{|\pi_t^b \cap \pi_t^e|}{K}. \quad (21)$$

Overlap@5 越高，说明整体分支与局部分支的高排名候选越一致，但该指标必须与 Rank-1 和 mAP 同时解释，避免把两路共同犯错误认为有效消歧。为进一步判断分歧变化是否指向正确目标，还应报告 BGE、TSE 的独立检索性能，以及交互后目标排名改善、持平和恶化的查询比例。

## 6.3 RSTPReid 上的公开结果坐标

表3汇总现有论文中能够核实的 RSTPReid 数值 [3–5]。CFine、IRRA、BiLMa、RaSa 和 RDE 为标准单轮结果；AUL 的数值由 DIDL 论文汇总；ICL + THI 和 DIDL 为各自论文报告的交互式结果。由于训练方式、回答来源和交互轮数不同，这些数字只作为文献坐标。

表 3: 原论文公开的 RSTPReid 检索结果 (%)。“–” 表示原文未报告该指标。

| 方法        | Rank-1↑ | Rank-5↑ | Rank-10↑ | mAP↑  | mINP↑ | 结果来源与协议        |
|-----------|---------|---------|----------|-------|-------|----------------|
| CFine     | 50.55   | 72.50   | 81.60    | –     | –     | RDE 表 6        |
| IRRA      | 60.20   | 81.30   | 88.20    | 47.17 | 25.28 | RDE 表 6        |
| BiLMa     | 61.20   | 81.50   | 88.80    | 48.51 | –     | RDE 表 6        |
| RaSa      | 66.90   | 86.50   | 91.35    | 52.31 | –     | RDE 表 6        |
| RDE       | 65.35   | 83.95   | 89.90    | 50.88 | 28.08 | RDE 表 6        |
| AUL       | 71.65   | 87.55   | 92.05    | –     | –     | DIDL 表 3       |
| ICL + THI | 70.55   | 85.95   | 91.65    | 53.68 | 30.13 | ICL 表 1, 5 轮   |
| DIDL      | 75.40   | 91.40   | 94.70    | –     | –     | DIDL 表 3, 多轮最终 |

## 6.4 DDI 的总体性能与逐轮变化

主实验只比较原始 RDE 与插入单个 DDI 模块后的结果。表4依次报告第 0 至第 3 轮，既能观察检索增益是否随交互累积，也能检验 BGE–TSE 候选重合率是否同步变化。

若 Rank-1、mAP 与 Overlap@5 同时提高，说明新增回答不仅使两路排序趋于一致，而且这种一致性指向了正确身份；若 Overlap@5 提高而准确率没有改善，则说明 MLLM 只是让两个分支共同收缩到了错误候选，需要在分析中如实报告。

表 4: RSTPReid 200-query subset 上 DDI 的待实验结果 (%)。

| 方法        | 轮次 | Rank-1↑ | Rank-5↑ | Rank-10↑ | mAP↑ | Overlap@5↑ | MLLM 调用/查询 |
|-----------|----|---------|---------|----------|------|------------|------------|
| RDE       | 0  | —       | —       | —        | —    | —          | 0          |
| RDE + DDI | 1  | —       | —       | —        | —    | —          | 2          |
| RDE + DDI | 2  | —       | —       | —        | —    | —          | 4          |
| RDE + DDI | 3  | —       | —       | —        | —    | —          | 6          |

## 6.5 分歧引导的最小消融

为了验证性能变化来自 RDE 内部的双粒度分歧，而不只是“向 MLLM 展示若干候选”，在与主实验相同的 200 条查询上进行一次单轮对照。通用候选交互直接展示 RDE 联合排序的 Top-5；DDI 则展示式(18)选出的双向分歧候选，并提供 BGE/TSE 排名与 TSE 细粒度文本线索。两种设置使用相同 MLLM、问题数量、回答代理和 RDE 骨干。

表 5: RSTPReid 200-query subset 上分歧引导方式的单轮消融。

| 交互输入         | 双排序信息 | TSE 线索 | Rank-1↑ | mAP↑ | Overlap@5↑ |
|--------------|-------|--------|---------|------|------------|
| 联合排序 Top-5   |       |        | —       | —    | —          |
| BGE-TSE 分歧候选 | ✓     | ✓      | —       | —    | —          |

除定量结果外，定性分析可展示 BGE Top-5、TSE Top-5、TSE 细粒度文本线索、DDI 问答和交互前后目标排名，用于说明双向分歧如何转化为具体人物属性问题。

# 7 开放挑战与未来方向

## 7.1 真实用户意图与代理评测之间的差距

【写作要点】讨论 MLLM 看到目标图像后生成答案与真实用户依赖记忆回答之间的差异，推动建立带真实交互轨迹的 TIReID 基准。

## 7.2 交互幻觉、偏见与隐私

【写作要点】分析人物性别、年龄和身份相关提问的偏见风险，避免要求用户提供与检索无关的敏感属性。讨论监控图像进入外部 MLLM 的隐私与部署限制。

## 7.3 从单锚点到多假设意图建模

【写作要点】发展候选集合级推理、贝叶斯信念更新和可撤销查询状态，使系统在早期候选错误时仍能恢复。

## 7.4 成本感知与可部署交互

【写作要点】研究小模型问题策略、属性缓存、批量候选描述和分层 *MLLM* 调用，降低测试时延迟。建立准确性、用户负担和计算成本的帕累托评价。

## 8 结语

【写作要点】总结跨模态噪声对应学习与 *MLLM* 测试时交互的互补关系。强调 *RDE* 的 *BGE-TSE* 双粒度分歧能够为测试时提问提供模型内部依据，并以单一 *DDI* 模块作为从静态 *RDE* 基线迈向交互检索的可执行路径。

## 参考文献

- [1] Saehyung Lee, Sangwon Yu, Junsung Park, Jihun Yi, and Sungroh Yoon. Interactive text-to-image retrieval with large language models: A plug-and-play approach. *arXiv preprint arXiv:2406.03411*, 2024.
- [2] Matan Levy, Rami Ben-Ari, Nir Darshan, and Dani Lischinski. Chatting makes perfect: Chat-based image retrieval. In *Advances in Neural Information Processing Systems*, volume 36, 2023. NeurIPS 2023; arXiv:2305.20062.
- [3] Hongyu Liu, Hongwei Ge, Yuxuan Liu, and Yaqing Hou. Dialogue-driven interactive dynamic learning for text-to-image person retrieval. In *Proceedings of the 33rd ACM International Conference on Multimedia*, pages 9177–9185, Dublin, Ireland, 2025. ACM. doi: 10.1145/3746027.3754583.
- [4] Yang Qin, Yingke Chen, Dezhong Peng, Xi Peng, Joey Tianyi Zhou, and Peng Hu. Noisy-correspondence learning for text-to-image person re-identification. *arXiv preprint arXiv:2308.09911*, 2024.
- [5] Yang Qin, Chao Chen, Zhihang Fu, Dezhong Peng, Xi Peng, and Peng Hu. Human-centered interactive learning via mllms for text-to-image person re-identification. *arXiv preprint arXiv:2506.11036*, 2025.